

Obtención de coberturas del suelo agropecuarias en imágenes satelitales Sentinel-2 con la inyección de imágenes de dron usando *Random Forest* en *Google Earth Engine*

Ramírez, M. ^{*}, Martínez, L. , Montilla, M. , Sarmiento, O. , Lasso, J. , Díaz, S. 

Grupo de Investigación y Desarrollo de la Dirección Técnica de Geoestadística, Departamento Administrativo Nacional de Estadística, Cra. 59 #26-60, Bogotá D.C., Colombia.

Resumen: Para obtener información precisa sobre los cambios de la cubierta terrestre en el sector agrícola, proponemos un método de clasificación supervisada que integra las imágenes del satélite Sentinel-2 con las imágenes obtenidas de los Sistemas de Aeronaves Pilotadas a Distancia (RPAS, por sus siglas en inglés). La metodología se aplicó en la plataforma de *Google Earth Engine*. Inicialmente, la colección de imágenes de Sentinel-2 se integró en una sola imagen mediante un proceso de reducción de mediana. Posteriormente, se aplicó el método de fusión de imágenes de *pansharpening* con filtro de paso alto (HPF, por sus siglas en inglés) a las bandas espectrales térmicas para obtener una resolución espacial final de 10 m. Para realizar la integración de las dos fuentes de imágenes, la imagen del RPAS se normalizó utilizando un filtro de textura gaussiano de 5x5 y el píxel se re-muestreó a cinco veces su tamaño original. Este procedimiento se realizó de forma iterativa hasta alcanzar la resolución espacial de la imagen del Sentinel-2. Además, se añadieron a la clasificación los siguientes datos: los índices espectrales, calculados a partir de las bandas de Sentinel-2 y RPAS (por ejemplo, NDVI, NDWI, SIPI, GARI), la información altimétrica y las pendientes de la zona derivadas del MED SRTM. La clasificación supervisada se realizó utilizando la técnica de *Random Forest (Machine Learning)*. La referencia de la semilla de la cubierta terrestre para realizar la clasificación fue capturada manualmente por un experto temático, luego, esta referencia fue distribuida en un 70% para el entrenamiento del algoritmo de *Random Forest* y en un 30% para validar la clasificación. Los resultados muestran que la incorporación de la imagen RPAS mejora los indicadores de precisión temática en un promedio del 3% en comparación con una clasificación realizada exclusivamente con imágenes de Sentinel-2.

Palabras clave: Sentinel-2, RPAS, *Google Earth Engine*, clasificación supervisada, *Random Forest*.

Obtaining agricultural land cover in Sentinel-2 satellite images with drone image injection using *Random Forest* in *Google Earth Engine*

Abstract: To obtain accurate information on land cover changes in the agricultural sector, we propose a supervised classification method that integrates Sentinel-2 satellite imagery with images surveyed from Remote Piloted Aircraft Systems (RPAS). The methodology was implemented on the *Google Earth Engine* platform. Initially, the Sentinel-2 imagery collection was integrated into a single image through a median reduction process. Subsequently, the high-

To cite this article: Ramírez, M., Martínez, L., Montilla, M., Sarmiento, O., Lasso, J., Díaz, S. 2020. Obtaining agricultural land cover in Sentinel-2 satellite images with drone image injection using *Random Forest* in *Google Earth Engine*. *Revista de Teledetección*, 56, 49-68. <https://doi.org/10.4995/raet.2020.14102>

* Corresponding author: maramirezg@dane.gov.co

pass filter (HPF) pansharpener image fusion method was applied to the thermal spectral bands to obtain a final spatial resolution of 10 m. To perform the integration of the two image sources, the RPAS image was normalized by using a 5X5 gaussian texture filter and the pixel was resampled to five times its original size. This procedure was performed iteratively until reaching the spatial resolution of the Sentinel-2 imagery. Besides, the following inputs were added to the classification: the spectral indices, calculated from the Sentinel-2 and RPAS bands (e.g. NDVI, NDWI, SIPI, GARI), altimetric information and slopes of the zone derived from the SRTM DEM. The supervised classification was done by using the Random Forest technique (Machine Learning). The land cover seed reference to perform the classification was manually captured by a thematic expert, then, this reference was distributed in 70% for the training of the Random Forest algorithm and in 30% to validate the classification. The results show that the incorporation of the RPAS image improves thematic accuracy indicators by an average of 3% compared to a classification made exclusively with Sentinel-2 imagery.

Key words: Sentinel-2, RPAS, Google Earth Engine, supervised classification, Random Forest.

1. INTRODUCCIÓN

La demanda de información espacial de alto nivel de detalle del sector agrícola crece diariamente, ya que a partir de esta es posible realizar una gestión de información agropecuaria de confianza que permita la toma de decisiones de los productores respecto a sus cultivos, y de todo un país respecto al fortalecimiento de las políticas de desarrollo rural, seguridad alimentaria y competitividad del sector agropecuario (FAO, 2013; MADR, 2018). Para cumplir con este requerimiento se hace necesario aplicar el uso de tecnologías innovadoras y el desarrollo de metodologías que faciliten la obtención y procesamiento de la información para alcanzar resultados con un mayor grado de exactitud, de manera que los datos estadísticos publicados respondan a las necesidades de los distintos actores del sector agropecuario (French et al., 2014; Corpoica, 2015).

Mediante la teledetección, definida como una técnica a partir de la cual se adquieren imágenes, se procesan y se interpretan de forma visual o digital para extraer información de las coberturas presentes (Chuvienco, 2008), es posible llevar a cabo dicho objetivo. Haciendo uso de imágenes satelitales se puede relacionar la información fisiológica de los cultivos con la energía reflejada por los mismos a diferentes longitudes de onda y, de esta manera, diferenciar al cultivo propiamente dicho, la maleza, determinar los niveles de nutrientes, o incluso detectar enfermedades y plagas (González y Cancela, 2018).

Sin embargo, algunos autores han concluido que estas imágenes del terreno están condicionadas por las limitantes en cuanto a resolución espacial

y temporal de las imágenes disponibles se refiere (Sebem et al., 2005; Berni et al., 2009; Gevaert et al., 2015), ya que considera que estas resoluciones son inadecuadas al permitir obtener un resultado de carácter más general, no pertinente para parcelas pequeñas, además de la necesidad de correcciones geométricas y radiométricas (León, 2002). Por otro lado, el auge de los Sistemas de Aeronaves Pilotadas a Distancia, conocidos por las siglas en inglés RPAS o más comúnmente conocidas como drones, junto con los avances en el desarrollo de los microsensores, han planteado el uso de estas plataformas como nuevos medios de teledetección que permiten adquirir un mayor conocimiento de los recursos bajo estudio y ser aplicado en la resolución de problemas específicos (Díaz García-Cervigón, 2015).

Recientemente se han realizado estudios (Dash et al., 2018; Pla et al., 2019; Zhao et al., 2019) que han propuesto el uso de estos dispositivos como medios que, al ser integrados con información satelital, permitan mejorar la clasificación de las coberturas del suelo con fines agropecuarios y/o de monitoreo forestal.

La información hiperespectral de imágenes satelitales ha sido integrada con la información adicional que proveen las observaciones multi-espectrales de RPAS, obteniendo un perfil de ese mismo instante mucho más completo de las coberturas presentes por una toma satelital (Gevaert et al., 2015), dado que las imágenes RPAS, por ser tomadas debajo de la atmósfera y a una mayor resolución espacial, poseen información espectral más específica de la cobertura de interés. La combinación de imágenes satelitales Landsat y de RPAS, es llevada a cabo para aplicaciones

agrícolas, especialmente para distinguir tipos de cultivo (Jenerowicz y Woroszkiewicz, 2016); la misma combinación ha sido realizada con el fin de monitorear el hábitat de los orangutanes, donde los datos de RPAS se usan para entrenar al algoritmo de clasificación *Random Forest* y se aplican a los datos de Landsat para diferenciar clases de uso de la tierra relevantes para la conservación del hábitat (Szantoi et al., 2017).

Los datos resultantes del RPAS han sido utilizados como información equivalente a la verdad-terreno y como posterior validación de información de imágenes satelitales Landsat (Pla et al., 2017). Para detectar estrés por herbicidas en una especie arbórea, las imágenes de RPAS se han remuestreado a la misma resolución espacial de la información hiperespectral de imágenes Formosat 2, explorando la relación entre ambas mediante modelos de regresión por mínimos cuadrados ordinarios y *Random Forest* (Dash et al., 2018).

Por otro lado, también se ha llevado a cabo el procedimiento Gram-Schmidt para la fusión de imágenes satelitales con imágenes de RPAS, pero en este caso con imágenes Sentinel-2A para cartografiar, mediante *Random Forest*, *Support Vector Machine* y *Neural Networks*, la distribución de cultivos a una escala espacial más fina (Zhao et al., 2019). Con el fin de estimar los daños en los cultivos de arroz de la región Delta del Ebro se han calibrado igualmente imágenes Sentinel-2 a partir de información capturada con RPAS, extrapolando el modelo generado a la imagen satelital completa (Pla et al., 2019).

En las investigaciones (Dash et al., 2018; Pla et al., 2019; Zhao et al., 2019) se concluyó que la combinación de las imágenes provenientes de ambas plataformas da como resultado un producto con una mejor resolución espacial, temporal y espectral. Además, a partir de los distintos métodos de clasificación aplicados a las mismas, se evidencia que los mejores resultados son obtenidos al entrenar el algoritmo de clasificación de *Machine*

Learning, *Random Forest* (Belgiu y Csillik, 2017; Chen et al., 2017; Dash et al., 2018; Zhao et al., 2019); por lo tanto, estos insumos son una herramienta eficaz para discriminar clases de cobertura del suelo.

La presente investigación surgió de la necesidad manifestada por la Dirección técnica de Geoestadística (DIG) del Departamento Administrativo Nacional de Estadística (DANE) de la mejora y actualización continua de la variable uso del suelo del Marco Maestro Rural Agropecuario (MMRA) (DANE, 2019) usando técnicas de teledetección, con el propósito de fortalecer la producción de información estadística agropecuaria de Colombia y el diseño del muestreo de la Encuesta Nacional Agropecuaria (ENA). Por consiguiente, esta investigación propone una clasificación supervisada usando *Random Forest* que integra imágenes satelitales Sentinel-2 (debido a su adecuada resolución espacial y a su fácil accesibilidad) con imágenes capturadas con RPAS implementada en su totalidad en la plataforma de procesamiento en la nube *Google Earth Engine*. Con el propósito de explorar métodos alternativos para la obtención de información con mayor precisión de la cobertura del suelo del sector agropecuario (especialmente la diferenciación de cultivos permanentes y transitorios de otras coberturas vegetales como bosque) y aportar en la generación de información estadística del sector agropecuario colombiano.

2. METODOLOGÍA

2.1. Zona de estudio

El estudio se realizó en cuatro municipios de Colombia (Figura 1) sobre los que se contaba con imágenes de RPAS, correspondientes a Salento en el departamento del Quindío y Tununguá, Pajarito y Cóbbita en el departamento de Boyacá. En la Tabla 1, se aprecia la distribución territorial de estas regiones que poseen vocación agropecuaria.

Tabla 1. Distribución territorial de las zonas de estudio

Municipio	Zona Urbana	Zona Rural	Total	Fuente
	Extensión (ha)	Extensión (ha)	Extensión (ha)	
Salento	60	37705	377.7	IGAC
Tununguá	1540	6160	77	IGAC
Pajarito	20	32190	322.1	IGAC
Cóbbita	46	14854	149	(Puerto-Caro et al., 2019)




Figura 1. Localización de las zonas de estudio.

2.2. Materiales

Para la clasificación, se emplearon las imágenes satelitales multiespectrales de alta resolución espacial (HR) de la misión Sentinel-2 disponibles en el repositorio de la plataforma *Google Earth Engine* en nivel de procesamiento 2A, conocido también como *Surface Reflectance* (SR) (ESA, 2013), que asegura que las imágenes poseen calibración radiométrica, corrección geométrica y se encuentran en valor de reflectancia sobre la superficie de la tierra (Kuhn et al., 2019); además, el instrumento multi-espectral S2 (MSI) muestrea trece bandas espectrales, a saber; RGB y NIR a un GSD de 10 metros, *Red Edge* y SWIR a un GSD de 20 metros, y bandas atmosféricas a una resolución espacial de 60 metros; estas últimas no fueron utilizadas en la investigación presentada. Con el propósito de asegurar la existencia de correspondencia temporal entre las imágenes Sentinel-2 y RPAS, las fechas

de toma de las imágenes satelitales usadas en cada una de las áreas de estudio fueron establecidas en función del día de toma de las imágenes de RPAS, como se observa en la Tabla 2.

Los ortofotomosaicos de imágenes de RPAS utilizados como insumo para mejorar la clasificación fueron proporcionados por diferentes fuentes, por tanto, poseen diferentes características en cuanto a la resolución espacial, espectral y temporal, pero todos poseen algún tipo de calibración radiométrica que asegura que los valores de píxel de las ortoimágenes se encuentren en términos de reflectancia, como se relaciona en la Tabla 3.

2.3. Métodos

El flujo metodológico se concentra en tres etapas (Figura 2) definidas como: (i) preprocesamiento de los datos, (ii) clasificación supervisada de la

Tabla 2. Características de la colección de imágenes Sentinel-2.

Zona	Rango de Fechas	Número de imágenes
Salento	11/09/2019	2
Tununguá	07/08/2018	1
Pajarito rural y urbano	24/08/2018-18/09/2018	3
Cómbita	01/01/2019	1

Tabla 3. Características de las imágenes de RPAS.

Descripción	Imagen	
Salento Área: 3950 ha Sensor: Parrot Sequoia-eBee Bandas: Red, Green, Red Edge, NIR Resolución espacial: 0.48m Fecha de toma: 20/09/2019		Combinación: RGB (NIR-Red Edge-Red)
Tununguá Área: 2100 ha Sensor: SODA-eBee Bandas: Red, Green, Blue Resolución espacial: 0.5m Fecha de toma: 05/08/2018-06/08/2018		Combinación: RGB (Blue-Green-Red)
Pajarito Rural Área: 310 ha Sensor: SODA-eBee Bandas: Red, Green, Blue Resolución espacial: 0.45m Fecha de toma: 02/08/2018 Combinación: RGB		Combinación: RGB (Blue-Green-Red)
Pajarito Urbano Área: 220 ha Sensor: SODA-eBee Bandas: Red, Green, Blue Resolución espacial: 0.45m Fecha de toma: 02/08/2018 Combinación: RGB		Combinación: RGB (Blue-Green-Red)
Combita Área: 35 ha Sensor: FC330_3.6 -Phantom4 Bandas: Red, Green, Blue Resolución espacial: 0.5 m Fecha de toma: 29/11/2018		Combinación: RGB (Blue-Green-Red)

imagen y, por último, (iii) análisis comparativo de los resultados. Las dos primeras etapas y la primera actividad de la tercera etapa son realizadas completamente en la plataforma de *Google Earth Engine* (GEE). El script limpio de GEE se encuentra en la siguiente URL (es necesario cargar el límite de la zona de interés y la imagen RPAS, además de seguir las instrucciones consignados en el mismo para que funcione adecuadamente):

<https://code.earthengine.google.com/ed7fb21921955866ea5479a6a35f4cb8>

2.3.1. Preprocesamiento y preparación de datos

Al cargar el repositorio Sentinel-2 en procesamiento SR (COPERNICUS/S2_SR) se realiza la acotación de la colección en los aspectos de porcentaje de nubosidad, es decir, la cantidad de




Figura 2. Flujo de trabajo

nubes permitidas por el intérprete, que en este caso corresponde a 40%, el rango de tiempo en que se realiza la búsqueda de imágenes, y la definición y corte a partir del área de estudio. Se aplica una máscara de nubosidad a cada imagen de la colección, que es producto de la identificación y corte de las zonas que de acuerdo con la banda de calidad QA60 posee presencia de nubes y cirrus (Traganos et al., 2018). Esta acción disminuye la posibilidad de que existan nubes en el mosaico.

Con el propósito de realizar la clasificación a partir de una sola imagen se emplea una reducción de la colección de las imágenes generando un mosaico de medianas, puesto que no es afectada por valores de reflectancia atípicos; al seleccionar el valor de la mediana de cada píxel genera una imagen homogénea en el espacio y tiempo que probablemente disminuye las afectaciones por presencia de nubes y fuentes de contaminación (Flood, 2013).

Debido a que la resolución espacial de las bandas espectrales RGB varía con respecto a la de SWIR-1, SWIR-2 y Red Edge de Sentinel-2 en razón de 10 m a 20 m respectivamente, se realiza sobre el mosaico de medianas el proceso de fusión de imágenes *pansharpening* con el fin de mejorar la resolución espacial de todas las bandas Sentinel-2 sin perder la resolución espectral original (Li et al., 2018). El proceso empleado se realiza a partir del método de filtro de paso alto (HPF, por sus siglas en inglés), el cual es frecuentemente utilizado en imágenes satelitales HR (Kaplan, 2018) y su implementación en GEE es sencilla (HC, 2019). El proceso de fusión HPF requiere de una imagen pancromática derivada del valor promedio de las bandas espectrales de 10 m y a su vez del comportamiento estadístico de las bandas de 20 m para la posterior aplicación del filtro de paso alto y así obtener las bandas finales (Palubinskas, 2013).

Para integrar las imágenes de RPAS al mosaico de mediana fueron consideradas las limitantes relacionadas con las resoluciones espaciales y temporales de cada uno de los insumos, debido a que no son comparables entre sí (Rocchini, 2007). Por un lado, el mosaico de medianas corresponde al comportamiento mediano espectral de las coberturas en un rango de tiempo y es tomado fuera de la atmósfera mientras que la imagen RPAS representa la toma espectral de una fecha específica por debajo de la atmósfera a un tamaño de píxel mucho más detallado. Lo anterior, obliga a garantizar la existencia de puntos comunes de comparación, las dos imágenes se deben encontrar

en un nivel de reflectancia preferiblemente cercano al de superficie (Nonni et al., 2018) y que para realizar la comparación espacial se siga un procedimiento estricto y exhaustivo de normalización entre las dos fuentes de información, lo cual es asegurado en los dos insumos utilizados como se evidenció en la sección de materiales.

Considerando que el propósito es la exploración de métodos que permitan la identificación de coberturas agropecuarias de grandes extensiones, se decide que es apropiado realizar la clasificación a la resolución espacial de Sentinel-2. Para llevar a cabo la normalización de la imagen de RPAS y como propuesta de los autores, se emplea un filtro de textura gaussiano de tamaño 5×5 y se realiza un remuestreo de la imagen a cinco veces el tamaño del píxel de forma iterativa hasta obtener un tamaño de píxel cercano al del mosaico Sentinel-2 para, finalmente, realizar un re-muestreo ponderado a una resolución de 10 m. El proceso se visualiza de forma más detallada en la Figura 3. Cabe mencionar, además, que la aplicación de este filtro recrea los fundamentos teóricos de toma del *Instantaneous Field Of View* (IFOV). Para fijar el número de iteraciones (*n*) necesarias se aplica la fórmula (1), donde la función *E*[*x*] corresponde a la función parte entera, que está condicionada en que la resolución espacial objetivo final es de 10 m.

$$n = E \left[\frac{\ln \left(\frac{10}{\text{resolución original}} \right)}{\ln 5} \right] \tag{1}$$




Figura 3. Re-muestreo de la imagen de RPAS.

Una vez las imágenes cuentan con las mismas características se apilan las bandas de las imágenes de Sentinel-2 y las bandas remuestreadas de las imágenes RPAS en un mismo ráster. Adicionalmente, con el fin de mejorar la diferenciación de las coberturas de interés, se agrega al ráster con las bandas apiladas el corte del DEM SRTM de resolución espacial de 30 m, disponible en el repositorio de GEE y el ráster de pendientes, calculado a partir del DEM mencionado.

Como información de referencia espectral para mejorar la clasificación final, tanto para el mosaico de medianas como para la imagen de RPAS remuestreada, se calculan y agregan los índices espectrales de la Tabla 4. Se debe aclarar que el cálculo de los índices espectrales respectivos fue realizado de acuerdo con la resolución espectral (Tabla 3) de la imagen de mejor resolución espacial.

2.3.2. Clasificación supervisada

La clasificación se realizó para dos escenarios: el primero corresponde a solo el mosaico Sentinel-2 y el segundo al mosaico Sentinel-2 con la inyección de la imagen RPAS.

Inicialmente, un fotointérprete experto capturó manualmente los polígonos de los cultivos presentes en la imagen y, a partir de estos, se generaron distintas opciones de datos de entrenamiento, para así seleccionar la muestra que tuviera mejores indicadores de exactitud temática en la clasificación realizada exclusivamente en el mosaico Sentinel-2. Dicha muestra fue igualmente utilizada para la clasificación del segundo escenario mencionado anteriormente. Las muestras seleccionadas fueron generalizadas en las coberturas establecidas por el Marco Maestro Rural Agropecuario (MMRA) colombiano (DANE, 2019) y, con el fin de presentar los resultados, fueron adaptadas a las que presenta la metodología *Corine Land Cover*, siguiendo el procedimiento mostrado en la Figura 4. La muestra se dividió en dos conjuntos de datos: uno correspondiente al de entrenamiento y el otro al de validación. Para la selección del conjunto de datos de validación fueron tomadas las recomendaciones realizadas por Millard y Richardson, en donde el 30% del total de la muestra corresponde a la información de validación (Millard y Richardson, 2015); su selección se realiza a partir de números aleatorios con una semilla predispuesta, que en este caso es cero, y producto de la verificación de un “*spatial join*” entre los datos de entrenamiento y los preseleccionados de validación, con

Tabla 4. Índices espectrales calculados para la clasificación.

Nombre	Significado	Fórmula	Fuente
NDVI	Índice de vegetación de diferencia normalizada	$\frac{NIR - RED}{NIR + RED}$	(Rouse et al., 1973)
SIPI	Índice de pigmentación intensiva de la estructura	$\frac{NIR - BLUE}{NIR - RED}$	(Peñuelas et al., 1995)
PVR	Relación de vigor fotosintético	$\frac{GREEN - RED}{GREEN + RED}$	(Metternicht, 2003)
VARI	Índice de resistencia atmosféricamente visible	$\frac{GREEN - RED}{GREEN + RED - BLUE}$	(Gitelson et al., 2002)
GARI	Índice Verde Resistente Atmosféricamente	$\frac{NIR - (GREEN - \lambda(BLUE - RED))}{NIR + (GREEN - \lambda(BLUE - RED))}$ $\lambda \rightarrow$ Parámetro que controla la corrección atmosférica	(Viña et al., 2011)
NDBI	Índice de áreas construidas de diferencia normalizada	$\frac{SWIR - NIR}{SWIR + NIR}$	(Zha et al., 2003)
NDWI	Índice de agua de diferencia normalizada	$\frac{GREEN - NIR}{GREEN + NIR}$	(Gao, 1996)



Figura 4. Procedimiento para el trazo de los datos de entrenamiento.

el propósito de que no exista autocorrelación espacial con la muestra de entrenamiento. Además, mantener fija la muestra de entrenamiento bajo el escenario planteado asegura que el resultado de la clasificación no difiera en caso de que el proceso sea realizado múltiples veces en las mismas condiciones y, por lo tanto, el árbol de decisión seleccionado por el algoritmo *random forest* solo difiera si el ráster es distinto.

El algoritmo usado para la clasificación supervisada basada en píxeles es de *Machine Learning*, *Random Forest*, pues según la revisión literaria realizada es el más usado y con mejores resultados, obteniendo la mejor exactitud temática para la adquisición de información agropecuaria (Belgiu y Csillik, 2017; Chen et al., 2017; Dash et al., 2018; Zhao et al., 2019). Los parámetros utilizados en el algoritmo de *random forest* son 100 árboles y 4 ramificaciones, debido a que presentaron mejores indicadores de desempeño en las pruebas realizadas por los autores; el número de ramificaciones fue establecido de acuerdo a la recomendación teórica de Belgiu y Drăgu (2016) quienes argumentan que debe ser la raíz cuadrada del número de clases objetivo.

Como indicadores de la calidad temática de toda la clasificación, se utilizan las métricas más representativas que corresponden a porcentaje de clasificación del mapa, calidad del productor, calidad del usuario y el índice kappa, este último debido a que no posee sesgo derivado de los errores de omisión y comisión (Foody, 2002; Liu

et al., 2007) y a nivel de cobertura se utilizan los errores de omisión y comisión. Los anteriores indicadores son derivados de la matriz de confusión generada a partir de la comparación del resultado de la clasificación y la muestra definida para la validación.

La clasificación final se selecciona a partir de la revisión de los indicadores de exactitud temática junto a una validación visual aleatoria de las coberturas clasificadas. A la clasificación final se le aplica un filtro de moda de tamaño 3×3 , debido a que este procedimiento atenúa los píxeles aislados que fueron clasificados de forma puntual y permite que se cumpla con criterios técnicos cartográficos como el área mínima cartografiable, lo que proporciona un producto final mucho más homogéneo debido a que elimina errores residuales del proceso de clasificación (Stuckens et al., 2000).

2.3.3. Análisis comparativo de los resultados

Como última actividad, y después de generar los vectores de la clasificación final junto al cálculo de las áreas relativas dadas en porcentaje por cada cobertura dentro del conglomerado (Unidad mínima geográfica del MMRA), se realizó un análisis comparativo de los resultados mencionados con los reportados por el proceso de fotointerpretación manual realizado para las mismas fechas de estudio. El proceso de fotointerpretación fue realizado por la Dirección de Geoestadística (DIG) del DANE con la imagen satelital base de *Google*

Earth. Esta actividad tiene el propósito de determinar las ventajas y desventajas de la metodología propuesta respecto a la obtención de áreas de coberturas por proceso de fotointerpretación que se ha realizado dentro de la entidad.

3. RESULTADOS

Los resultados son presentados para cada una de las tres etapas de la metodología.

3.1. Preprocesamiento y preparación de los datos

La investigación se desarrolló en cuatro zonas de estudio, limitadas a las áreas con imágenes RPAS. A continuación, los resultados se focalizan en Salento, con el propósito de ilustrar cada uno de los pasos automatizados en el *script* de GEE.

El primer resultado corresponde a la generación del mosaico de medianas y aplicación de máscara de nubosidad que se observa en la Figura 5.

Para Salento solamente se encuentran dos imágenes Sentinel-2 disponibles (Tabla 2), se observa

en la Figura 5 que estas cubren totalmente la zona de estudio. En el mosaico de medianas, además del corte, se evidencia el efecto de la máscara de nubosidad en la reducción de la zona sur del área de interés.

Para realizar la inyección de la imagen RPAS al mosaico Sentinel-2, fue realizado un remuestreo iterativo a partir de un filtro gaussiano. El resultado se observa en la Figura 6.

Para la muestra del proceso de remuestreo de la imagen RPAS presentada en la Figura 6, fue seleccionada intencionalmente una zona con múltiples coberturas con el propósito de mostrar visualmente que las características de textura de cada una de ellas se preservan a pesar de la generalización espacial y, por consiguiente, es adecuada esta característica en la clasificación de coberturas como se en la observa en la Figura 5.

Por último, en la Tabla 5, se presentan el número de capas que fueron utilizados en la clasificación de cada una de las zonas de estudio, observándose hasta 29 capas. Las capas corresponden a las bandas espectrales Sentinel-2, las bandas de la




Figura 5. Imágenes Sentinel-2 y mosaico de medianas de Sentinel-2 con máscara de nubes.




Figura 6. Imagen RPAS y producto del re-muestreo de la imagen RPAS comparando con la imagen Sentinel-2.

Tabla 5. Capas utilizadas en cada zona de estudio.

Zona	Sentinel-2	RPAS	SRTM-30	Total capas
Salento	Blue, Red, Green, Red Edge-1, Red Edge-2, Red Edge-3, Red Edge-4, NIR, SWIR-1, SWIR-2, NDVI, SIPI, PVR, VARIgreen, GARI, NDBI, NDWI	Red, Green, Red Edge, NIR, NDVI, PVR, VARIgreen,	DEM, pendiente	28
Tununguá	Blue, Red, Green, Red Edge-1, Red Edge-2, Red Edge-3, Red Edge-4, NIR, SWIR-1, SWIR-2, NDVI, SIPI, PVR, VARIgreen, GARI, NDBI, NDWI	Blue, Red, Green, PVR, VARIgreen	DEM, pendiente	24
Pajarito rural y urbano	Blue, Red, Green, Red Edge-1, Red Edge-2, Red Edge-3, Red Edge-4, NIR, SWIR-1, SWIR-2, NDVI, SIPI, PVR, VARIgreen, GARI, NDBI, NDWI	Blue, Red, Green, PVR, VARIgreen	DEM, pendiente	24
Cómbita	Blue, Red, Green, Red Edge-1, Red Edge-2, Red Edge-3, Red Edge-4, NIR, SWIR-1, SWIR-2, NDVI, SIPI, PVR, VARIgreen, GARI, NDBI, NDWI	Blue, Red, Green, NIR, NDVI, SIPI, PVR, VARIgreen, GARI, NDWI	DEM, pendiente	29

imagen remuestreada de RPAS, el DEM, el ráster de pendientes derivado del DEM y los índices espectrales que fueron calculados tanto para las bandas del mosaico sentinel-2, como para las bandas de la imagen re-muestrada RPAS; el número de índices calculados para las imágenes de RPAS varía en función de la resolución espectral.

3.2. Clasificación supervisada con Random Forest

El conjunto de datos de referencia, expuestos en la Figura 7, de las coberturas de Salento fueron capturados por un fotointérprete experto a nivel de cultivo, dejando un cubrimiento regular en toda la zona de estudio, y a partir de esta se seleccionó la muestra de entrenamiento que obtuviera una mejor clasificación del mosaico Sentinel-2. Posteriormente, fueron generalizadas en las categorías del MMRA y Corine Land Cover. Este mismo procedimiento fue realizado para las demás zonas de estudio. Conforme a la metodología planteada las muestras se distribuyeron en datos de entrenamiento y validación. Cabe resaltar que, indiferente a la geometría en la que se hallan capturadas las muestras, el algoritmo las asume en términos de píxel. La Tabla 6, resume el número de píxeles usados como datos de entrenamiento y validación por cada una de las coberturas en las diferentes zonas de estudio.

La Figura 8 y Figura 9 comparan los resultados obtenidos al realizar la clasificación con la imagen

Sentinel-2 y con la imagen Sentinel-2 incluyendo la imagen de RPAS, respectivamente. Analizando el resultado de las clasificaciones en todo su conjunto no se observan mejoras significativas de la clasificación que incluye imágenes RPAS con respecto a la realizada con solo imágenes Sentinel-2. Sin




Figura 7. Muestras de entrenamiento de experto a nivel de cultivo, zona de estudio Salento.

Tabla 6. Distribución por pixeles de las muestras de entrenamiento (E) y validación (V).

Clase	Salento		Tununguá		Pajarito Rural		Pajarito Urbano		Combita	
	E	V	E	V	E	V	E	V	E	V
1.1. Zonas urbanizadas	49	32	14	3	72	12	115	17	13	3
2.1. Cultivos transitorios	99	41	138	69	0	0	0	0	30	8
2.2. Cultivos permanentes	1153	293	747	273	0	0	0	0	0	0
2.3. Pastos	239	68	448	270	140	50	98	9	49	21
2.5. Suelo en Preparación	0	0	0	0	0	0	7	0	19	6
2.6. Cultivos sin clasificar	0	0	151	81	0	0	0	0	0	0
3.1. Bosques	865	493	434	201	209	127	258	105	17	20
3.2. Áreas con vegetación herbácea y/o arbustiva	0	0	477	225	0	0	0	0	0	0
3.3. Áreas abiertas, sin o con poca vegetación	0	0	74	30	0	0	62	20	0	0
3.3.1 Zonas arenosas naturales	47	9	60	3	0	0	0	0	0	0
5.1. Aguas continentales	66	33	0	0	41	25	55	34	0	0
6.1. Nubes	0	0	50	124	0	0	0	0	0	0
Total	2518	969	2593	1279	462	214	595	185	128	58

embargo, en casos específicos, se evidencian mejoras en la definición de los límites de las coberturas. Por ejemplo, en la Figura 10, en las filas A y C, se observa una mejor delimitación entre la cobertura de bosques y en la fila B, se observa una mejor delimitación del río.

De las clasificaciones presentadas se obtienen los porcentajes de error de omisión y comisión relacionados en la Tabla 7 y Tabla 8, respectivamente, donde se comparan los resultados al realizar la clasificación solo con la imagen satelital Sentinel-2

con los resultados de la integración con la imagen de RPAS.

De acuerdo con la Tabla 7, las coberturas que reflejan mejores resultados al realizar la clasificación con la integración de los insumos son los cultivos transitorios y permanentes presentes en las zonas de Salento y Tununguá, los pastos presentes en las zonas de Pajarito urbano y rural y el bosque natural presente en todas las imágenes.

La Tabla 9 compara la precisión general y el indicador kappa obtenidos como resultado de la

Tabla 7. Síntesis de los errores de comisión.

	Error de Comisión									
	Sentinel-2					Sentinel-2 y RPAS				
	Salento	Tununguá	Pajarito Rural	Pajarito Urbano	Cómbita	Salento	Tununguá	Pajarito Rural	Pajarito Urbano	Cómbita
1.1. Zonas urbanizadas	0,0%	89,5%	20,0%	22,7%	0,0%	0,0%	25,0%	0,0%	15,8%	0,0%
2.1. Cultivos transitorios	46,5%	18,3%			0,0%	25,9%	20,6%			20,0%
2.2. Cultivos permanentes	8,9%	31,0%				10,1%	28,1%			
2.3. Pastos	3,9%	23,1%	6,3%	14,3%	8,7%	6,1%	24,0%	3,8%	10,0%	0,0%
2.5. Suelo en Preparación					25,0%					25,0%
2.6. Cultivos sin clasificar		2,5%					4,8%			
3.1. Bosques	1,2%	6,3%	1,6%	0,0%	0,0%	0,8%	2,9%	0,0%	0,0%	0,0%
3.2. Áreas con vegetación herbácea y/o arbustiva		31,7%					28,4%			
3.3. Áreas abiertas, sin o con poca vegetación		0,0%		17,6%			0,0%		12,5%	
3.3.1 Zonas arenosas naturales	33,3%	0,0%				20,0%	0,0%			
5.1. Aguas continentales	9,1%		0,0%	3,0%		13,9%		0,0%	3,0%	
6.1. Nubes		1,0%					0,0%			




Figura 8. Resultados de clasificación con coberturas generales con Sentinel-2 y con la inyección RPAS.

clasificación realizada solo con la imagen satelital Sentinel-2 y la clasificación realizada al integrar la imagen de RPAS. La precisión general es un índice que no tiene en cuenta los errores de omisión y comisión, datos que sí son tenidos en cuenta por el indicador Kappa.

De acuerdo con la Tabla 9, los resultados tanto de la precisión general como del índice Kappa se incrementan al realizar la clasificación a partir de la integración de la imagen Sentinel-2 con la imagen del RPAS, fluctuando desde un 2% a 26,7% los indicadores de exactitud temática.

Tabla 8. Síntesis de los errores de omisión.

	Error de Omisión									
	Sentinel-2					Sentinel-2 y RPAS				
	Salento	Tununguá	Pajarito Rural	Pajarito Urbano	Cómbita	Salento	Tununguá	Pajarito Rural	Pajarito Urbano	Cómbita
1.1. Zonas urbanizadas	46,9%	33,3%	0,0%	0,0%	0,0%	31,3%	0,0%	0,0%	5,9%	0,0%
2.1. Cultivos transitorios	7,3%	29,0%			25,0%	2,4%	27,5%			0,0%
2.2. Cultivos permanentes	8,9%	26,7%				6,1%	24,9%			
2.3. Pastos	27,9%	22,2%	10,0%	33,3%	0,0%	32,4%	18,9%	0,0%	0,0%	9,5%
2.5. Suelo en Preparación					0,0%					0,0%
2.6. Cultivos sin clasificar		3,7%					2,5%			
3.1. Bosques	1,4%	4,0%	1,6%	0,0%	10,0%	1,0%	0,5%	0,8%	0,0%	10,0%
3.2. Áreas con vegetación herbácea y/o arbustiva		32,9%					31,6%			
3.3. Áreas abiertas, sin o con poca vegetación		3,3%		30,0%			6,7%		30,0%	
3.3.1 Zonas arenosas naturales	11,1%	0,0%				11,1%	0,0%			
5.1. Aguas continentales	9,1%		4,0%	5,9%		6,1%		4,0%	5,9%	
6.1. Nubes		21,8%					16,1%			

Tabla 9. Síntesis de calidad temática.

Zona de Estudio	Salento			Tununguá			Pajarito Rural			Pajarito Urbano			Cómbita		
Experimento	S2	S2/ RPAS	Var.	S2	S2/ RPAS	Var.	S2	S2/ RPAS	Var.	S2	S2/ RPAS	Var.	S2	S2/ RPAS	Var.
Precisión General	0,92	0,94	1,5%	0,79	0,82	2,6%	0,96	0,99	2,8%	0,94	0,95	1,1%	0,74	0,96	21,8%
Indicador Kappa	0,88	0,90	2,4%	0,75	0,78	3,0%	0,94	0,98	4,8%	0,90	0,92	1,8%	0,54	0,81	26,7%




Figura 9. Comparación visual coberturas clasificadas bajo los dos enfoques.




Figura 10. Comparación del proceso de fotointerpretación (izquierda) con el proceso de clasificación supervisada (derecha). Comparan el tanto por cien de cobertura con un mapa de clasificación.

3.3. Análisis con los resultados obtenidos por fotointerpretación

Por otro lado, la Figura 10, muestra la comparación de los resultados de la clasificación realizada en Tununguá con los resultados del proceso de fotointerpretación realizado en el año 2019 por parte del DANE con imágenes de *Google Earth* del año 2017. Para esta etapa se tiene en cuenta que el porcentaje de área que representa cada una de las coberturas en el conglomerado es de interés en la actualización de MMRA. Por lo anterior, el análisis se realiza a este nivel; esta comparación, tiene el propósito de explorar las variaciones que se derivan de las dos formas en las que se puede obtener las coberturas agropecuarias.

De acuerdo con la Tabla 10, el resultado del proceso de clasificación en la clase pastos, presentó una variación de -32,3% con respecto al porcentaje reportado a través de la fotointerpretación. Tal vez esta situación se deba a que en la clasificación realizada se tenga dificultades para identificar los pastos, pero si se observan los índices de calidad, estos indican que el porcentaje de omisión para esta clase es del 18,9% en Tununguá, lo cual no explica totalmente la diferencia del resultado; por tanto, se puede sugerir que la diferencia se deba a

la subjetividad del interprete, quien posiblemente tienda a favorecer en la clase pastos y prestar menos interés en las clase bosques y/o áreas abiertas, sin o con poca vegetación.

4. DISCUSIÓN

Los trabajos previos disponibles (Dash et al., 2018; Zhao et al., 2019) que tratan la clasificación supervisada con *Random Forest* en imágenes Formosat 2 y Sentinel-2 buscaron la obtención de coberturas más generales y no en específicamente cultivos. Por lo anterior, la primera parte de la discusión se centra en analizar solamente los resultados con el conocimiento que se posee de las zonas de estudio.

A partir de los resultados de las clasificaciones realizadas en la investigación, se determinan diferentes comportamientos que tienen algunas coberturas presentes en las imágenes y cómo estos se ven reflejados una vez se ha asignado cada píxel a una categoría. Para las zonas de Salento y Tununguá, que cuentan con la presencia de cultivos transitorios y permanentes, y por lo tanto, los resultados son comparables entre sí, se tiene que el error de comisión, consignado en la Tabla 7,

Tabla 10. Comparación de áreas, clasificación supervisada vs. fotointerpretación masiva.

Método	2.1. Cultivos transitorios	2.2. Cultivos permanentes	2.3. Pastos	2.6. Cultivos sin clasificar	3.1. Bosques	3.3. Áreas abiertas, sin o con poca vegetación
Clasificación	0,58%	28,88%	14,93%	1,41%	38,28%	15,92%
Fotointerpretación	0,18%	29,32%	47,24%	0%	21,84%	1,44%
Diferencia	0,40%	-0,44%	-32,32%	1,41%	16,44%	14,48%

es significativamente mayor en la clasificación realizada solo con Sentinel-2, con excepción de la cobertura de pastos para la zona de Salento donde el error es mayor un 2% en el resultado de Sentinel-2 con RPAS. Este resultado que se adjudica al número de muestras tomadas para dicha cobertura que, en el caso de Salento fueron 73, correspondientes solo al 14% del total de las muestras tomadas, y en Tununguá fueron 81, correspondientes a un 19% del total de las muestras, situación que se presenta de forma similar en el error de omisión, consignado en la Tabla 8.

Las coberturas de bosque, zonas urbanizadas y zonas arenosas naturales, coberturas presentes en ambas imágenes, presentan diferencias significativas para estos valores, siendo el error mucho más alto, tanto de omisión como de comisión, en la clasificación de imágenes con solo Sentinel-2.

Los resultados anteriores permiten inferir que el uso de la imagen de mejor resolución espacial es un insumo que brinda mejores resultados para zonas amplias con coberturas heterogéneas. En las imágenes capturadas de la zona de Pajarito, divididas en uso urbano y rural, se tiene que, para la cobertura de pastos, el error de omisión se presenta únicamente en la clasificación con solo imágenes Sentinel-2, siendo además valores considerables; el error de comisión se presenta en ambas clasificaciones, siendo ya un error aludido a la delimitación hecha por el intérprete, sin embargo, este sigue siendo mayor para la versión anteriormente nombrada. La cobertura de áreas abiertas, sin o con poca vegetación, presente únicamente en la zona urbana de Pajarito, en ambos errores generó valores mayores para la clasificación con integración de RPAS, ya que al llevarse a cabo con esta versión tendió a confundirse un poco más con la cobertura de suelo en preparación. Las demás coberturas identificadas: bosques, zonas urbanizadas, y aguas continentales, presentan valores parecidos de error de omisión en ambas metodologías, por lo que generan resultados similares cuando se trata de coberturas que no tienden a variar su estructura significativamente con el paso del tiempo. El error de comisión para estas mismas coberturas sí fue mayor con la clasificación de la sola imagen Sentinel-2, por lo que se puede decir que la integración con RPAS tiende a dejar de lado los errores cometidos por el intérprete.

La zona de Cómbita, al corresponder a un área tan pequeña, no permite tomar un número de muestras

suficientes tal que el algoritmo pueda entrenarse de forma idónea, por lo que los resultados no generan valores reveladores, más allá de una distinción visual de las coberturas.

La Tabla 9a indica que en un promedio de 3% los indicadores de exactitud temática mejoraron en la comparación de las dos metodologías (solo Sentinel-2 vs. Sentinel-2 integrado con RPAS). Aunque la mejora puede parecer no significativa, uno de los aspectos que se debe considerar, como se mencionó previamente, se refiere al mejoramiento de la delimitación de cada una de las coberturas en todas las zonas de estudio desde una perspectiva visual y también evidenciados en los errores de comisión y omisión de las coberturas objetivo. Esta característica fue importante en la zona de menor área correspondiente a Cómbita.

En cuanto a lo que se refiere a la fusión de la imagen Sentinel-2 y RPAS, tiene el objetivo de aumentar la resolución espectral del insumo objetivo (mosaico Sentinel-2), siendo el mismo que buscaron Zhao et al., (2019). Estos autores realizaron una investigación similar a la presentada, pero su propósito fue fortalecer la resolución espectral a resoluciones espaciales cercanas a las de las imágenes RPAS con la información multi-espectral de las imágenes Sentinel-2. De esta manera se buscó que fuera efectiva esta característica en los resultados de la clasificación supervisada a nivel de cultivos desagradados, siendo este mismo el proceso decisivo de la investigación presentada.

No obstante, a partir de los resultados del trabajo de Zhao et al., (2019), se evidencia que lo que para ellos fue un inconveniente (aplicar el método en resoluciones espaciales alejadas de la original del RPAS), en esta investigación fue una fortaleza. De acuerdo con los resultados de la mayoría de los experimentos realizados con cultivos desagregados, arrojaron índices de calidad cercanos al 90%, además de demostrar efectividad en áreas de estudios amplias (Salento y Tununguá), mientras que en el estudio referenciado el promedio fue del 75%. Por otro lado, se debe mencionar como debilidad de la investigación realizada y de las mencionadas que con las condiciones dispuestas no es posible extrapolar la información precisa que contiene la imagen de mejor resolución espacial a otras zonas geográficas tomadas solamente por la imagen satelital analizada.

Por último, referente a la comparación de los resultados obtenidos con lo existente por métodos de fotointerpretación manual realizados por el DANE, se puede identificar una diferencia entre el número de clases identificadas en cada uno de los métodos. En el caso del método de clasificación con GEE, en doce de los catorce conglomerados comparados reportan un número mayor de clases con respecto al proceso de fotointerpretación. En los otros dos conglomerados se reportan el mismo número de clases. Se infiere que el proceso de clasificación semiautomatizado en GEE permite la discriminación de clases que en el proceso de fotointerpretación son omitidas, dado que en el proceso de fotointerpretación el análisis se hace sobre imágenes con una combinación en color verdadero. En cambio la clasificación en GEE incorpora un mayor número de bandas, el modelo digital del terreno e índices espectrales.

5. Conclusiones

El proceso de clasificación supervisada de coberturas semiautomatizado en la plataforma *Google Earth Engine* y el uso de algoritmos de *Machine Learning*, representa una mejora y fortalecimiento sustancial en el proceso de actualización de la información estadística agropecuaria colombiana en particular para las labores propias que posee a su dirección el DANE, como la reducción de subjetividad, puesto que el intérprete solo interviene capturando las muestras de entrenamiento; los demás subprocesos están parametrizados, lo que garantiza que todas clasificaciones se realicen bajo los mismos criterios. Por otro lado, la metodología propuesta incorpora hasta veintinueve variables en el algoritmo de clasificación, por lo tanto, aumenta la probabilidad de tener una clasificación aceptable y la identificación de clases que por medio de fotointerpretación son omitidas.

Para aquellas zonas que cuentan con presencia de cultivos transitorios y/o permanentes, contar con una imagen adquirida mediante un RPAS supone una enorme ventaja en términos de precisión en la delimitación de las coberturas e identificación de aquellas que se encuentran dispuestas en áreas pequeñas, como fue el caso de Salento. Por otro lado, en las demás zonas de estudio, la imagen de mejor resolución espacial permite definir de forma más precisa los bordes de un cuerpo de agua, de una carretera, las fronteras entre cubiertas con

características a simple vista similares, como los bosques y las áreas con vegetación herbácea y/o arbustiva, entre otros, todo esto demostrado en los resultados de las clasificaciones realizadas.

A partir del análisis de los resultados obtenidos de la clasificación de cada una de las zonas propuestas, se establece una consideración relevante a ser tenida en cuenta para el aprovechamiento del *script* que integra la información del satélite y del RPAS. Hace referencia a la importancia de contar con información con fechas de adquisición cercanas entre ellas, con el fin de que el estado de las coberturas bajo estudio sea comparable y no posean modificaciones en su estructura y varíe de una imagen a otra.

Sin lugar a duda se puede indicar que la integración de imágenes de muy alta resolución espacial con una imagen satelital de media resolución, siendo en este caso RPAS y Sentinel-2, respectivamente, mediante un filtro de textura gaussiano y remuestreo iterativo, el cual fortalece la resolución espectral, proporciona mejores resultados en la clasificación supervisada con respecto a los obtenidos con un enfoque de solo imágenes satelitales. No obstante, se debe mencionar que este mejoramiento está limitado exclusivamente a las zonas geográficas cubiertas completamente por estos dos productos y que los resultados pueden variar en cierto grado dependiendo de las características propias de las imágenes de mejor resolución espacial.

Aunque los resultados son prometedores, es importante en este tipo de investigaciones el estudio y exploración de métodos estadísticos que permitan la extrapolación de la información precisa de las imágenes de mejor resolución espacial a zonas de la imagen satelital de menor resolución espacial. Además de contemplar el uso de métodos que le brinden al clasificador la riqueza multitemporal de las imágenes de distintas fechas que permita la discriminación de los cultivos en especial la diferenciación entre los transitorios de los permanentes. Con respecto al insumo base, este tipo de investigaciones debería contemplar la inclusión de imágenes de sensores no ópticos, en especial para la generación de información geoespacial de las zonas del país que poseen nubosidad constante.

Referencias

- Belgiu, M., Csillik, O. 2017. Sentinel-2 cropland mapping using pixel-based and object-based time-weighted dynamic time warping analysis. *Remote Sensing of Environment*, 204(2018), 509-523. <https://doi.org/10.1016/j.rse.2017.10.005>
- Berni, J.A.J., Zarco-Tejada, P.J., Suárez, L., Fereres, E. 2009. Thermal and narrowband multispectral remote sensing for vegetation monitoring from an unmanned aerial vehicle. *Ieee Transactions on Geoscience and Remote Sensing*, 47(3), 722-738. <https://doi.org/10.1109/TGRS.2008.2010457>
- Chen, W., Xie, X., Wang, J., Pradhan, B., Hong, H., Bui, D.T., Duan, Z., Ma, J. 2017. A comparative study of logistic model tree, random forest, and classification and regression tree models for spatial prediction of landslide susceptibility. *Catena*, 151(2017), 147-160. <https://doi.org/10.1016/j.catena.2016.11.032>
- Chuvieco, E. 2008. *Teledeteccion ambiental*. Barcelona: Ariel, S.A.
- Corpoica. Ciencia, Tecnología e Innovación en el Sector Agropecuario (Diagnóstico para la Misión para la Transformación del Campo). *Departamento Nacional de Planeación-Biblioteca*. Último acceso: 13 de Mayo, 2020, de https://colaboracion.dnp.gov.co/CDT/Agriculturapecuarioforestal_y_pesca/Diagnostico_de_la_Ciencia_Tecnologia_e_Innovacion_en_el_Sector_Agropecuario-CORPOICA.pdf
- DANE. Marco Maestro Rural Y Agropecuaria - Conceptualización Básica. *DANE Información para todos*. Último acceso: 13 de Mayo, 2020, de https://geoportal.dane.gov.co/descargas/mmra/pdf/2019_MMRA_DOCUMENTO_V1.pdf
- Dash, J.P., Pearse, G.D., Watt, M.S. 2018. UAV multispectral imagery can complement satellite data for monitoring forest health. *Remote Sensing*, 10(8), 1-22. <https://doi.org/10.3390/rs10081216>
- Díaz García-Cervigón, J.J. 2015. *Estudio de Índices de vegetación a partir de imágenes aéreas tomadas desde UAS/RPAS y aplicaciones de estos a la agricultura de precisión* [Universidad Complutense de Madrid]. https://eprints.ucm.es/31423/1/TFM_Juan_Diaz_Cervignon.pdf
- ESA. Sentinel-2 User Handbook. *Sentinel online*. Último acceso: 8 de Julio, 2020, de https://sentinels.copernicus.eu/documents/247904/685211/Sentinel-2_User_Handbook
- FAO. 2013. *Plan de acción de la estrategia global para el mejoramiento de las estadísticas agropecuarias y rurales*. Roma: Banco Mundial.
- Flood, N. 2013. Seasonal composite landsat TM/ETM+ images using the medoid (a multi-dimensional Median). *Remote Sensing*, 5(12), 6481-6500. <https://doi.org/10.3390/rs5126481>
- Foody, G.M. 2002. Status of land cover classification accuracy assessment. *Remote Sensing of Environment*, 80(1), 185-201. [https://doi.org/10.1016/S0034-4257\(01\)00295-4](https://doi.org/10.1016/S0034-4257(01)00295-4)
- Gao, B.C. 1996. NDWI—A normalized difference water index for remote sensing of vegetation liquid water from space. *Remote sensing of environment*, 58(3), 257-266. [https://doi.org/10.1016/S0034-4257\(96\)00067-3](https://doi.org/10.1016/S0034-4257(96)00067-3)
- Gevaert, C.M., Suomalainen, J., Tang, J., Kooistra, L. 2015. Generation of spectral-temporal response surfaces by combining multispectral satellite and hyperspectral UAV imagery for precision agriculture application. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 8(6), 3140-3146. <https://doi.org/10.1109/JSTARS.2015.2406339>
- Gitelson, A.A., Kaufman, Y.J., Stark, R., Rundquist, D. 2002. Novel algorithms for remote estimation of vegetation fraction. *Remote Sensing of Environment*, 80(1), 76-87. [https://doi.org/10.1016/S0034-4257\(01\)00289-9](https://doi.org/10.1016/S0034-4257(01)00289-9)
- González, X., Cancela, J. 2018. Utilización de imágenes de satélite y drones en horticultura. *Canales sectoriales interempresas*. Último acceso: 13 de Mayo, 2020, de <https://www.interempresas.net/Horticola/Articulos/206464-Utilizacion-de-imagenes-de-satelite-y-drones-en-horticultura.html>
- HC, T. 2019. Pansharpening Sentinel-2 imagery in Google Earth Engine. *Landscape Ecology & Conservation Lab*. Último acceso: 13 de Mayo, 2020, de <https://leclab.wixsite.com/spatial/post/pansharpening-sentinel-2-imagery-in-google-earth-engine>
- French, J., Montiel, K., Palmieri, V. 2014. *La innovación en la agricultura: un proceso clave para el desarrollo sostenible*. San José: IICA.
- Jenerowicz, A., Woroszkiewicz, M. 2016. The pansharpening of satellite and UAV imagery for agricultural applications. En: *Remote Sensing for Agriculture, Ecosystems, and Hydrology XVIII*. Edinburgh, United Kingdom. 26-28 Septiembre. pp 674. <https://doi.org/10.1117/12.2241645>
- Kaplan, G. 2018. Sentinel-2 pansharpening-Comparative analysis. *Proceedings*, 2(7), 345. <https://doi.org/10.3390/eers-2-05158>

- Kuhn, C., de Matos Valerio, A., Ward, N., Loken, L., Sawakuchi, H.O., Kampel, M., Richey, J., Stadler, P., Crawford, J., Striegl, R., Vermote, E., Pahlevan, N., Butman, D. 2019. Performance of Landsat-8 and Sentinel-2 surface reflectance products for river remote sensing retrievals of chlorophyll-a and turbidity. *Remote Sensing of Environment*, 224(January), 104-118. <https://doi.org/10.1016/j.rse.2019.01.023>
- León, Y. Introducción a las Imágenes Satelitales. *Nanopdf*. Último acceso: 16 de Mayo, 2020, de https://nanopdf.com/download/introduccion-a-las-imagenes-satelitales_pdf.
- Li, Y., Qu, J., Dong, W., Zheng, Y. 2018. Hyperspectral pansharpening via improved PCA approach and optimal weighted fusion strategy. *Neurocomputing*, 315, 371-380. <https://doi.org/10.1016/j.neucom.2018.07.030>
- Liu, C., Frazier, P., Kumar, L. 2007. Comparative assessment of the measures of thematic classification accuracy. *Remote Sensing of Environment*, 107(4), 606-616. <https://doi.org/10.1016/j.rse.2006.10.010>
- MADR. (2018). Estrategia de Política Pública para la Gestión Integral de Riesgos Agropecuarios en Colombia. *Minagricultura*. Último acceso: 13 de Mayo, 2020, de <https://www.minagricultura.gov.co/Documents/LIBRO%20ESTRATEGIA%20VERSION%20FINAL.pdf>
- Metternicht, G. 2003. Vegetation indices derived from high-resolution airborne videography for precision crop management. *International Journal of Remote Sensing*, 24(14), 2855-2877. <https://doi.org/10.1080/01431160210163074>
- Millard, K., Richardson, M. 2015. On the importance of training data sample selection in Random Forest image classification: A case study in peatland ecosystem mapping. *Remote Sensing*, 7(7), 8489-8515. <https://doi.org/10.3390/rs70708489>
- Nonni, F., Malacarne, D., Pappalardo, S.E., Codato, D., Meggio, F., De Marchi, M. 2018. Sentinel-2 Data Analysis and Comparison with UAV Multispectral Images for Precision Viticulture. *GI Forum*, 6(1), 105-116. https://doi.org/10.1553/giscience2018_01_s105
- Palubinskas, G. 2013. Fast, simple, and good pansharpening method. *Journal of Applied Remote Sensing*, 7(1), 073526. <https://doi.org/10.1117/1.jrs.7.073526>
- Peñuelas, J., Baret, F., Filella, I. 1995. Semi-empirical indices to assess carotenoids/chlorophyll a ratio from leaf spectral reflectance. *Photosynthetica*, 31, 221-230.
- Pla, M., Duane, A., Brotons, L. 2017. Potencial de las imágenes UAV como datos de verdad terreno para la clasificación de la severidad de quema de imágenes landsat: Aproximaciones a un producto útil para la gestión post incendio. *Revista de Teledetección*, 49, 91-102. <https://doi.org/10.4995/raet.2017.7140>
- Pla, M., Bota, G., Duane, A., Balagué, J., Curcó, A., Gutiérrez, R., Brotons, L. 2019. Calibrating Sentinel-2 imagery with multispectral UAV derived information to quantify damages in mediterranean rice crops caused by western swamphen (Porphyrrio porphyrio). *Drones*, 3(2), 45. <https://doi.org/10.3390/drones3020045>
- Puerto-Caro, N., Rios-Monroy, A., & Upegui, E. 2019. Estimación de la distribución espacial del control terrestre para el proceso fotogramétrico utilizando aeronaves remotamente pilotadas. *Teledetección: hacia una visión global del cambio climático*, 357-360.
- Rocchini, D. 2007. Effects of spatial and spectral resolution in estimating ecosystem α -diversity by satellite imagery. *Remote Sensing of Environment*, 111(4), 423-434. <https://doi.org/10.1016/j.rse.2007.03.018>
- Rouse, J.W., Haas, R.H., Schell, J.A., Deering, D.W. 1973. Monitoring vegetation systems in the Great Plains with ERTS. In *3rd ERTS Symposium, NASA SP-351 I*, pp. 309-317.
- Sebem, E., González Rivera, C., de la Vega Panizo, R., Valverde Gonzalo, A. 2005. Aportación del NDVI y los sistemas expertos en la mejora de la clasificación temática de imágenes multispectrales. En: *Anais Do XII Symposium Brasileiro de Sensoriamento Remoto*. Goiânia, Brasil, 16-21 Abril. pp 2763-2771.
- Stuckens, J., Coppin, P.R., Bauer, M.E. 2000. Integrating contextual information with per-pixel classification for improved land cover classification. *Remote Sensing of Environment*, 71(3), 282-296. [https://doi.org/10.1016/S0034-4257\(99\)00083-8](https://doi.org/10.1016/S0034-4257(99)00083-8)
- Szantoi, Z., Smith, S.E., Strona, G., Koh, L.P., Wich, S.A. 2017. Mapping orangutan habitat and agricultural areas using Landsat OLI imagery augmented with unmanned aircraft system aerial photography. *International Journal of Remote Sensing*, 38(8-10), 2231-2245. <https://doi.org/10.1080/01431161.2017.1280638>

- Traganos, D., Aggarwal, B., Poursanidis, D., Topouzelis, K., Chrysoulakis, N., Reinartz, P. 2018. Towards global-scale seagrass mapping and monitoring using Sentinel-2 on Google Earth Engine: The case study of the Aegean and Ionian seas. *Remote Sensing*, 10(8), 1227. <https://doi.org/10.3390/rs10081227>
- Viña, A., Gitelson, A.A., Nguy-Robertson, A.L., & Peng, Y. 2011. Comparison of different vegetation indices for the remote assessment of green leaf area index of crops. *Remote Sensing of Environment*, 115(12), 3468-3478. <https://doi.org/10.1016/j.rse.2011.08.010>
- Zha, Y., Gao, J., Ni, S. 2003. Use of normalized difference built-up index in automatically mapping urban areas from TM imagery. *International journal of remote sensing*, 24(3), 583-594. <https://doi.org/10.1080/01431160304987>
- Zhao, L., Shi, Y., Liu, B., Hovis, C., Duan, Y., Shi, Z. 2019. Finer Classification of Crops by Fusing UAV Images and Sentinel-2A Data. *Remote Sensing*, 11(24), 3012. <https://doi.org/10.3390/rs11243012>